

Sistema Inteligente de Alerta Temprana para la Identificación de Factores de Riesgo Bio-Conductuales y de Salud Mental en Adolescentes Salvadoreños

Universidad de El Salvador, Facultad de Ingeniería y Arquitectura, San Salvador, El Salvador
Curso de Especialización: Machine learning

Ing. Vladimir Díaz

Participantes:

Josías Abner Rivas Fuentes - RF20010,
Elmer Edenilson Rosales Molina - RM20001

Resumen—Este documento técnico presenta el diseño, implementación y optimización de un pipeline de Machine Learning aplicado a la salud pública de El Salvador, utilizando los datos de la Encuesta Global de Salud Escolar (GSHS) de 2013. El sistema aborda dos dimensiones críticas del bienestar adolescente: la estimación del Índice de Masa Corporal (IMC) a partir de variables puramente conductuales (Tarea A de Regresión) y la detección predictiva del riesgo en salud mental (Tarea B de Clasificación). Se implementaron tratamientos contra anomalías de coma flotante de desborde y se desarrollaron estrategias robustas para mitigar el severo desbalance de clases epidemiológico. A través de la optimización del umbral de decisión mediante la maximización del F1-Score, se logró un sistema de alta sensibilidad. Los hallazgos se traducen directamente en recomendaciones operacionales de políticas públicas orientadas a la optimización de recursos institucionales en los centros escolares de la República.

Index Terms—Machine Learning, Salud Pública, GSHS El Salvador, Random Forest, Optimización de Umbral, Índice de Masa Corporal, Salud Mental Adolescente.



1. INTRODUCCIÓN

La formulación de políticas públicas en el sector salud demanda, de manera creciente, la transición desde esquemas reactivos tradicionales hacia modelos predictivos basados en evidencia estocástica. En la República de El Salvador, la población adolescente se encuentra expuesta a determinantes sociales, económicos y biológicos complejos que moldean su perfil epidemiológico a largo plazo. Dos de los desafíos más apremiantes identificados por el Ministerio de Salud (MINSAL) corresponden a las alteraciones metabólico-nutricionales (malnutrición por exceso y déficit) y el espectro de vulnerabilidades asociadas a la salud mental.

Históricamente, los sistemas de vigilancia epidemiológica se han limitado al procesamiento descriptivo y retrospectivo de instrumentos de recolección masiva, como la Encuesta Global de Salud Escolar (GSHS) auspiciada por la OMS/OPS. Si bien estos reportes proporcionan una fotografía demográfica valiosa, carecen del dinamismo necesario para actuar como herramientas de alerta temprana a nivel individual o de centros escolares específicos.

Este estudio resuelve dicha limitación mediante el desarrollo de un pipeline predictivo automatizado de Machine Learning. El enfoque metodológico es doble: primero, se modela el Índice de Masa Corporal (IMC) abstrayendo las mediciones antropométricas directas, forzando al algoritmo a aprender los patrones ocultos en las conductas alimen-

tarias, de sedentarismo y de actividad física; segundo, se diagnostica el riesgo de afecciones en salud mental bajo condiciones extremas de desbalance de clase, calibrando matemáticamente la frontera de decisión para priorizar la sensibilidad clínica sin desbordar los recursos institucionales con falsas alarmas operacionales.

2. METODOLOGÍA Y PREPROCESAMIENTO

El éxito del pipeline radica en la rigurosidad del tratamiento de los datos. Se utilizó el conjunto de datos oficial `SLV2013_Public_Use.csv`, el cual consta de 104 variables originales y registros correspondientes a la población escolarizada del país.

2.1. Tratamiento de Anomalías Estructurales

Durante la auditoría inicial de los datos (EDA), se identificó un defecto crítico derivado de la migración de sistemas legados de SPSS/Stata hacia formatos abiertos de almacenamiento. Las respuestas omitidas o nulas (missing values) fueron codificadas erróneamente con el límite superior de representación numérica para coma flotante de doble precisión (64 bits), equivalente a un valor absoluto de $1,79769313486232 \times 10^{308}$.

Dejar este valor intacto invalidaría cualquier estimación estadística elemental (medias, varianzas, distancias euclidianas). El pipeline resolvió esto mediante una sustitución

vectorial generalizada, transformando dicho valor en nulos manejables (NaN) empleando las funciones vectorizadas de la librería Pandas, previniendo la distorsión de las funciones de pérdida de los modelos.

2.2. Definición Rigurosa de las Variables Objetivo

Para la **Tarea A (Regresión)**, el Índice de Masa Corporal se derivó mediante la relación matemática estándar de la Organización Mundial de la Salud, utilizando las variables declaradas de estatura ($Q4$) y peso ($Q5$):

$$IMC = \frac{Q5}{(Q4)^2} \quad (1)$$

Para la **Tarea B (Clasificación)**, se construyó la variable binaria *Riesgo_Salud_Mental* a partir de la variable original $Q25$ (y su correspondiente recodificación numérica $QN25$), la cual indaga sobre la presencia de ideación suicida o sentimientos persistentes de soledad/tristeza. **Justificación de la elección:** Esta variable fue seleccionada debido a que representa el marcador más severo y directamente asociado con trastornos depresivos mayores en la población adolescente, según los protocolos de la OMS para la GSHS. Detectar este riesgo permite implementar intervenciones tempranas de prevención del suicidio, lo cual es una prioridad de salud pública en El Salvador. Se codificó con el valor 1 (Presencia de Riesgo Alto) a los estudiantes que reportaron haber considerado seriamente intentar suicidarse en los últimos 12 meses, y con 0 (Ausencia de Riesgo Clínico) en caso contrario, revelando una prevalencia minoritaria fuertemente sesgada en los datos crudos (aproximadamente 12 % de casos positivos).

2.3. Mitigación del Data Leakage y Multicolinealidad

Un pilar fundamental de la rúbrica de evaluación es la prevención del *Data Leakage* (fuga de datos). Para la predicción del IMC, el modelo debe basarse puramente en conductas. En consecuencia, las variables físicas directas $Q4$ (estatura) y $Q5$ (peso) fueron removidas quirúrgicamente de la matriz de características del predictor. De igual forma, la variable base $Q25$ fue excluida de los predictores de clasificación.

Adicionalmente, el dataset original contiene las preguntas en formato categórico bruto ($Q1 - Q58$) y simultáneamente sus recodificaciones dicotómicas o numéricas precalculadas por los analistas de la OMS ($QN6 - QN58$). Incluir ambas dimensiones induciría una colinealidad perfecta o cuasi-perfecta, destruyendo la estabilidad de los coeficientes de regresión. Se optó por descartar la totalidad de las variables QN , manteniendo las preguntas originales para habilitar que las técnicas de codificación modernas capturen las relaciones no lineales complejas sin sesgos preexistentes.

2.4. Imputación, Codificación y Escalado Robustos

Dada la naturaleza categórica no ordinal de las encuestas, la pérdida de datos se subsanó mediante una estrategia de imputación basada en la moda (*most_frequent*) empleando *SimpleImputer* de Scikit-Learn. Esto impidió la generación de categorías decimales espurias que irrumpen al usar la media en encuestas sociales.

Posteriormente, se aplicó codificación *One-Hot Encoding* con eliminación de la primera columna dummificada (*drop_first=True*) para disolver la trampa de la dummificación múltiple. Finalmente, la matriz resultante fue transformada con *RobustScaler*, el cual utiliza la mediana y los rangos intercuartílicos (IQR), garantizando inmunidad frente a las respuestas atípicas extremas inherentes a los autorreportes de adolescentes.

3. MODELADO Y RESULTADOS TÉCNICOS

La experimentación se estructuró dividiendo los conjuntos de datos en un 70 % para entrenamiento, 20 % para validación y 10 % para prueba (o particiones equivalentes), asegurando una estratificación estricta en el caso del modelo de clasificación binaria.

3.1. Tarea A: Estimación del IMC

Se entrenaron de forma comparativa un modelo lineal paramétrico (Regresión Lineal) y un modelo basado en ensambles no lineales (Random Forest Regressor). Los resultados obtenidos se detallan en la Tabla 1.

Cuadro 1
Métricas de Rendimiento en la Estimación de IMC (Validación)

Algoritmo	RMSE (kg/m ²)	R ² Score
Regresión Lineal	3.9939	-0.0520
Random Forest Regressor	4.0578	-0.0859

Los resultados muestran que ambos modelos presentan un R^2 negativo, lo que indica que no logran explicar la varianza del IMC mejor que una predicción basada en la media. Esto es esperable debido a que el IMC es una medida antropométrica directa determinada fundamentalmente por el peso y la estatura, variables que fueron excluidas deliberadamente para evitar data leakage. El modelo de regresión no es adecuado para diagnóstico individual, sino que sirve como un sistema de alerta temprana a nivel poblacional, identificando patrones conductuales de riesgo que se correlacionan con problemas de salud.

3.1.1. Limitaciones del Modelo de Regresión (IMC)

Es importante destacar que el modelo de regresión diseñado para estimar el IMC presentó un desempeño limitado en cuanto a su poder predictivo absoluto, evidenciado por un bajo coeficiente de determinación (R^2) durante la validación cruzada. Este resultado es esperable y se justifica por la naturaleza de los datos y el diseño del experimento. El IMC es una medida antropométrica directa determinada fundamentalmente por el peso y la estatura del individuo. Al haber excluido deliberadamente estas variables ($Q4$ y $Q5$) del conjunto de características para evitar la fuga de datos (*data leakage*), el modelo se vio forzado a inferir el IMC basándose únicamente en factores conductuales indirectos (como hábitos alimenticios, actividad física y tiempo frente a pantallas).

Por lo tanto, el sistema no está diseñado para ser una herramienta de diagnóstico clínico individual para la obesidad, sino más bien como un sistema de alerta temprana

(*early-warning*) a nivel poblacional. La verdadera utilidad del modelo radica en su capacidad para identificar patrones conductuales de riesgo que se correlacionan con problemas de salud, más que en predecir el IMC exacto de un estudiante. La baja precisión en la regresión no invalida el proyecto, sino que resalta la complejidad de predecir medidas físicas a través de hábitos, reafirmando la importancia de la Tarea de Clasificación (Salud Mental) como el núcleo del sistema.

3.2. Tarea B: Clasificación de Riesgo de Salud Mental

El desafío principal de esta tarea radicaba en el marcado desbalance epidemiológico de las clases (donde los casos positivos representan menos del 12 % del total muestral). Para abordarlo, se utilizó el parámetro `class_weight='balanced'` en los modelos de Random Forest y Logistic Regression, y `scale_pos_weight` en XGBoost. Se probaron tres algoritmos: Regresión Logística, Random Forest y XGBoost. El mejor rendimiento, medido por F1-Score y AUC-ROC, fue alcanzado por Random Forest.

Además, se realizó una búsqueda del umbral óptimo de decisión sobre la curva Precisión-Recall, maximizando el F1-Score. El umbral óptimo se localizó en 0,49. Los resultados en el conjunto de validación se resumen en la Tabla 2.

Cuadro 2
Métricas de Clasificación (Validación)

Algoritmo	F1-Score	AUC-ROC	Umbral Óptimo
Regresión Logística	0.6420	0.9153	0.8151
Random Forest	0.6667	0.9487	0.4900
XGBoost	0.6420	0.9067	0.6530

El modelo Random Forest optimizado logró un F1-Score de 0.6667 y un AUC de 0.9487, indicando una excelente capacidad discriminativa. La matriz de confusión para el umbral óptimo mostró una reducción significativa de los Falsos Negativos en comparación con el umbral por defecto (0.5), lo que permite identificar a más estudiantes en riesgo sin generar un número excesivo de falsas alarmas.

Adicionalmente, se evaluó la capacidad de discriminación del modelo mediante la Curva ROC (Receiver Operating Characteristic), obteniéndose un Área Bajo la Curva (AUC) de **0.9487**. Esta métrica confirma que el clasificador posee una excelente capacidad para separar correctamente las clases de riesgo y no-riesgo, superando ampliamente el rendimiento de un clasificador aleatorio (AUC=0.5). La curva ROC correspondiente se presenta en la Figura 1.

4. INTERPRETACIÓN Y FACTORES DETERMINANTES

La extracción de las propiedades de importancia intrínseca del modelo (Feature Importance) permitió identificar los vectores conductuales y contextuales que detonan el riesgo en salud mental en los adolescentes salvadoreños. Las Figuras 4 y 5 muestran las variables más relevantes para cada tarea.

Los tres factores con mayor peso predictivo arrojados por el algoritmo corresponden a:




Figura 1. Curva ROC del mejor modelo de clasificación (Random Forest) optimizado para la detección de riesgo en salud mental.




Figura 2. Matriz de confusión del mejor modelo de clasificación sobre el conjunto de validación, aplicando el umbral óptimo calibrado (0.49).

1. **Acoso Escolar (Bullying):** La frecuencia de agresiones físicas o verbales dentro de las instalaciones escolares representó el predictor con mayor ganancia de información en los árboles de decisión.
2. **Ausencia de Factores de Protección Familiar:** Variables asociadas al monitoreo y acompañamiento de los padres (conocimiento de qué hacen los jóvenes en su tiempo libre o comprensión de sus problemas) exhibieron una correlación inversa directa con la presencia de riesgo.




Figura 3. Análisis de residuos del modelo de regresión (IMC): dispersión de residuos vs. predicción y distribución de errores.




Figura 4. Feature Importance del mejor modelo de clasificación de riesgo en salud mental (Random Forest). Las etiquetas provienen del codebook semántico del proyecto.




Figura 5. Feature Importance del mejor modelo de regresión de IMC (Random Forest).

3. **Consumo Temprano de Sustancias:** El acceso y consumo precoz de alcohol y tabaco actúa como un fuerte catalizador de desequilibrio emocional y sintomatología de riesgo.

5. RECOMENDACIONES DE POLÍTICA PÚBLICA

Traduciendo los hallazgos técnicos en decisiones estratégicas para el despacho ministerial, se plantean los siguientes ejes de intervención focalizada:

- **Despliegue de Unidades Móviles de Salud Mental Escolar:** Utilizando el modelo predictivo optimizado (umbral 0.49), el MINSAL puede mapear y clasificar los centros escolares del país. Aquellas escuelas cuyas encuestas agregadas arrojen altas probabilidades de riesgo colectivo deben recibir de forma prioritaria la asignación de psicólogos en planta, optimizando el presupuesto público del plan nacional de salud.
- **Intervención Interinstitucional MINSAL-MINED contra el Bullying:** Dado que el acoso escolar es la variable predictora predominante, no es posible solucionar la salud mental desde un enfoque puramente hospitalario. Se vuelve mandatorio co-diseñar junto al Ministerio de Educación protocolos vinculantes de prevención de violencia escolar, actuando directamente sobre la raíz del vector de riesgo.
- **Red de Alerta Temprana Automatizada:** Implementar a nivel nacional la infraestructura digital necesaria para que la GSHS u otros instrumentos de tamizaje escolar se digitalicen y procesen en tiempo real por

este pipeline predictivo. Esto facultará a las regiones de salud del MINSAL a recibir alertas tempranas semestrales y mitigar incidentes de autolesión antes de su ocurrencia.

- **Fortalecimiento de la Salud Mental y Apoyo Social:** La alta importancia de variables relacionadas con sentimientos de soledad, falta de amigos cercanos o bullying sugiere que el Ministerio debe priorizar el establecimiento de programas de contención psicológica y consejería escolar. Se recomienda la implementación de Clubes de Apoyo entre Pares y la capacitación de docentes para detectar signos tempranos de aislamiento social.
- **Prevención del Consumo de Sustancias:** La relevancia de las variables asociadas al consumo de alcohol o drogas indica una fuerte asociación con el riesgo de salud mental. Se sugiere intensificar las campañas de prevención en los centros educativos, enfocadas en la educación sobre los riesgos del consumo de sustancias, y establecer rutas claras de derivación a servicios de salud para jóvenes que presenten esta conducta.
- **Promoción de Entornos Escolares Seguros:** Las variables asociadas a experiencias de violencia y acoso escolar deben abordarse mediante políticas orientadas a la creación de protocolos estrictos contra el acoso (*anti-bullying*) y a la promoción de una cultura de respeto y no violencia dentro de las aulas. Esto incluye la creación de canales anónimos para reportar incidentes de acoso.
- **Educación Nutricional y Hábitos Saludables:** Aunque el modelo de IMC tuvo un rendimiento bajo, la presencia de variables alimentarias en el top 10 de la clasificación sugiere un vínculo entre los hábitos de alimentación no saludables y el deterioro de la salud mental. Se recomienda fomentar programas de alimentación saludable y huertos escolares que no solo aborden la nutrición, sino que también funcionen como espacios de integración social.

En conclusión, el sistema predictivo propuesto ofrece una herramienta de priorización para el MINSAL, permitiendo focalizar recursos (psicólogos, campañas, talleres) en las escuelas con mayor índice de riesgo, identificado a través de las variables de comportamiento que hemos destacado.

6. CONCLUSIONES

Este proyecto demuestra el inmenso valor de la Ciencia de Datos orientada a la salud de la República de El Salvador. Mediante la correcta estructuración y preprocesamiento de la información de la GSHS, se superó el obstáculo de los valores nulos anómalos y se previno el sesgo por Data Leakage al eliminar variables antropométricas en la estimación del IMC. Asimismo, la calibración matemática del umbral de decisión en el modelo Random Forest proveyó al Ministerio de Salud de una herramienta validada científicamente que balancea la sensibilidad clínica con la viabilidad financiera y operacional del estado, sentando las bases para una medicina preventiva moderna basada en algoritmos predictivos robustos.

El código fuente completo del pipeline, incluyendo los notebooks de EDA, feature engineering y modelado, se encuentra disponible en un repositorio público para garantizar la reproducibilidad de los resultados [5].

REFERENCIAS

- [1] Organización Mundial de la Salud, “Encuesta Global de Salud Escolar (GSHS): Resultados Oficiales de la República de El Salvador”, OPS/OMS, 2013.
- [2] L. Breiman, “Random Forests”, *Machine Learning*, vol. 45, no. 1, pp. 5-32, 2001.
- [3] T. Chen and C. Guestrin, “XGBoost: A Scalable Tree Boosting System”, en *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, 2016, pp. 785-794.
- [4] F. Pedregosa *et al.*, “Scikit-learn: Machine learning in Python”, *Journal of Machine Learning Research*, vol. 12, pp. 2825-2830, 2011.
- [5] J. A. Rivas Fuentes and E. E. Rosales Molina, “Sistema de Predicción de Factores de Riesgo en Adolescentes Salvadoreños,” GitHub repository, 2026. [Online]. Available: https://github.com/abner-rivas/Proyecto_minsal.git