

Sistema Inteligente de Alerta Temprana para la Identificación de Factores de Riesgo Bio-Conductuales y de Salud Mental en Adolescentes Salvadoreños

Desafío de Machine Learning – Informe Técnico Oficial
Stella Staff, Dirección de Planificación de Políticas Públicas
Ministerio de Salud (MINSAL), San Salvador, El Salvador

Resumen—Este documento técnico presenta el diseño, implementación y optimización de un pipeline avanzado de Machine Learning aplicado a la salud pública de El Salvador, utilizando los datos de la Encuesta Global de Salud Escolar (GSHS) de 2013. El sistema aborda dos dimensiones críticas del bienestar adolescente bajo un enfoque analítico riguroso: la estimación del Índice de Masa Corporal (IMC) a partir de variables puramente conductuales (Tarea A de Regresión) y la detección predictiva del riesgo multidimensional en salud mental (Tarea B de Clasificación). Se implementaron tratamientos contra anomalías de coma flotante de desborde y se desarrollaron estrategias robustas para mitigar el severo desbalance de clases epidemiológico. A través de la optimización hiperparamétrica con XGBoost y la calibración matemática del umbral de decisión mediante la maximización del F1-Score en la curva Precisión-Recall, se logró un sistema de alta sensibilidad capaz de minimizar los Falsos Negativos a niveles óptimos para la intervención temprana. Los hallazgos se traducen directamente en recomendaciones operacionales de políticas públicas orientadas a la optimización de recursos institucionales en los centros escolares de la República.

Index Terms—Machine Learning, Salud Pública, GSHS El Salvador, XGBoost, Optimización de Umbral, Índice de Masa Corporal, Salud Mental Adolescente.



1. INTRODUCCIÓN

La formulación de políticas públicas en el sector salud demanda, de manera creciente, la transición desde esquemas reactivos tradicionales hacia modelos predictivos basados en evidencia estocástica. En la República de El Salvador, la población adolescente se encuentra expuesta a determinantes sociales, económicos y biológicos complejos que moldean su perfil epidemiológico a largo plazo. Dos de los desafíos más apremiantes identificados por el Ministerio de Salud (MINSAL) corresponden a las alteraciones metabólico-nutricionales (malnutrición por exceso y déficit) y el espectro de vulnerabilidades asociadas a la salud mental.

Históricamente, los sistemas de vigilancia epidemiológica se han limitado al procesamiento descriptivo y retrospectivo de instrumentos de recolección masiva, como la Encuesta Global de Salud Escolar (GSHS, por sus siglas en inglés) auspiciada por la OMS/OPS. Si bien estos reportes proporcionan una fotografía demográfica valiosa, carecen del dinamismo necesario para actuar como herramientas de alerta temprana a nivel individual o de centros escolares específicos.

Este estudio resuelve dicha limitación mediante el desarrollo de un pipeline predictivo automatizado de Machine Learning. El enfoque metodológico es doble: primero, se modela el Índice de Masa Corporal (IMC) abstrayendo las mediciones antropométricas directas, forzando al algoritmo a aprender los patrones ocultos en las conductas alimen-

tarias, de sedentarismo y de actividad física; segundo, se diagnostica el riesgo de afecciones en salud mental bajo condiciones extremas de desbalance de clase, calibrando matemáticamente la frontera de decisión para priorizar la sensibilidad clínica sin desbordar los recursos institucionales con falsas alarmas operacionales.

2. METODOLOGÍA Y PREPROCESAMIENTO

El éxito del pipeline radica en la rigurosidad del tratamiento de los datos. Se utilizó el conjunto de datos oficial `SLV2013_Public_Use.csv`, el cual consta de 104 variables originales y registros correspondientes a la población escolarizada del país.

2.1. Tratamiento de Anomalías Estructurales

Durante la auditoría inicial de los datos (EDA), se identificó un defecto crítico derivado de la migración de sistemas legados de SPSS/Stata hacia formatos abiertos de almacenamiento. Las respuestas omitidas o nulas (missing values) fueron codificadas erróneamente con el límite superior de representación numérica para coma flotante de doble precisión (64 bits), equivalente a un valor absoluto de $1,79769313486232 \times 10^{308}$.

Dejar este valor intacto invalidaría cualquier estimación estadística elemental (medias, varianzas, distancias euclidianas). El pipeline resolvió esto mediante una sustitución

vectorial generalizada, transformando dicho valor en nulos manejables (NaN) empleando las funciones vectorizadas de la librería Pandas, previniendo la distorsión de las funciones de pérdida de los modelos.

2.2. Definición Rigurosa de las Variables Objetivo

Para la **Tarea A (Regresión)**, el Índice de Masa Corporal se derivó mediante la relación matemática estándar de la Organización Mundial de la Salud, utilizando las variables declaradas de estatura ($Q4$) y peso ($Q5$):

$$IMC = \frac{Q5}{(Q4)^2} \quad (1)$$

Para la **Tarea B (Clasificación)**, se construyó la variable binaria *Riesgo_Salud_Mental* mapeando las respuestas de la variable de ideación y sintomatología depresiva grave ($Q25$). Se codificó con el valor 1 (Presencia de Riesgo Alto) a los adolescentes que manifestaron de forma recurrente indicadores de planificación o consideración lesiva, y con 0 (Ausencia de Riesgo Clínico) en caso contrario, revelando una prevalencia minoritaria fuertemente sesgada en los datos crudos.

2.3. Mitigación del Data Leakage y Multicolinealidad

Un pilar fundamental de la rúbrica de evaluación es la prevención del *Data Leakage* (fuga de datos). Para la predicción del IMC, el modelo debe basarse puramente en conductas. En consecuencia, las variables físicas directas $Q4$ (estatura) y $Q5$ (peso) fueron removidas quirúrgicamente de la matriz de características del predictor. De igual forma, la variable base $Q25$ fue excluida de los predictores de clasificación.

Adicionalmente, el dataset original contiene las preguntas en formato categórico bruto ($Q1 - Q58$) y simultáneamente sus recodificaciones dicotómicas o numéricas precalculadas por los analistas de la OMS ($QN6 - QN58$). Incluir ambas dimensiones induciría una colinealidad perfecta o cuasi-perfecta, destruyendo la estabilidad de los coeficientes de regresión. Se optó por descartar la totalidad de las variables QN , manteniendo las preguntas originales para habilitar que las técnicas de codificación modernas capturen las relaciones no lineales complejas sin sesgos preexistentes.

2.4. Imputación, Codificación y Escalado Robustos

Dada la naturaleza categórica no ordinal de las encuestas, la pérdida de datos se subsanó mediante una estrategia de imputación basada en la moda (*most_frequent*) empleando *SimpleImputer* de Scikit-Learn. Esto impidió la generación de categorías decimales espurias que irrumpen al usar la media en encuestas sociales.

Posteriormente, se aplicó codificación *One-Hot Encoding* con eliminación de la primera columna dummificada (*drop_first=True*) para disolver la trampa de la dummificación múltiple. Finalmente, la matriz resultante fue transformada con *RobustScaler*, el cual utiliza la mediana y los rangos intercuartílicos (IQR), garantizando inmunidad frente a las respuestas atípicas extremas inherentes a los autorreportes de adolescentes.

3. MODELADO Y RESULTADOS TÉCNICOS

La experimentación se estructuró dividiendo los conjuntos de datos en un 80 % para entrenamiento y un 20 % para prueba, asegurando una estratificación estricta en el caso del modelo de clasificación binaria.

3.1. Tarea A: Estimación del IMC

Se entrenaron de forma comparativa un modelo lineal paramétrico (Regresión Lineal) y un modelo basado en ensambles no lineales (Random Forest Regressor). Los resultados obtenidos se detallan en la Tabla 1.

Cuadro 1
Métricas de Rendimiento en la Estimación de IMC

Algoritmo	RMSE (kg/m ²)	R ² Score
Regresión Lineal (Base)	3.1245	0.1142
Random Forest Regressor	2.8412	0.2389

El Random Forest exhibió una reducción notable del Error Cuadrático Medio (RMSE), consolidando un R^2 superior. Este comportamiento se justifica técnicamente debido a que los hábitos alimenticios y el sedentarismo no impactan el IMC de forma lineal; existen efectos de interacción multivariable complejos (ej. alta ingesta calórica combinada con nula actividad física y horas prolongadas de pantalla) que los árboles de decisión segmentan con mayor plasticidad que una ecuación hiperplana lineal.

3.1.1. Limitaciones del Modelo de Regresión (IMC)

Es importante destacar que el modelo de regresión diseñado para estimar el Índice de Masa Corporal (IMC) presentó un desempeño limitado en cuanto a su poder predictivo absoluto, evidenciado por un bajo coeficiente de determinación (R^2) durante la validación cruzada. Este resultado es esperable y se justifica por la naturaleza de los datos y el diseño del experimento. El IMC es una medida antropométrica directa determinada fundamentalmente por el peso y la estatura del individuo. Al haber excluido deliberadamente estas variables ($Q4$ y $Q5$) del conjunto de características para evitar la fuga de datos (*data leakage*), el modelo se vio forzado a inferir el IMC basándose únicamente en factores conductuales indirectos (como hábitos alimenticios, actividad física y tiempo frente a pantallas).

Por lo tanto, el sistema no está diseñado para ser una herramienta de diagnóstico clínico individual para la obesidad, sino más bien como un sistema de alerta temprana (*early-warning*) a nivel poblacional. La verdadera utilidad del modelo radica en su capacidad para identificar patrones conductuales de riesgo que se correlacionan con problemas de salud, más que en predecir el IMC exacto de un estudiante. La baja precisión en la regresión no invalida el proyecto, sino que resalta la complejidad de predecir medidas físicas a través de hábitos, reafirmando la importancia de la Tarea de Clasificación (Salud Mental) como el núcleo del sistema.

3.2. Tarea B: Clasificación de Riesgo de Salud Mental

El desafío principal de esta tarea radicaba en el marcado desbalance epidemiológico de las clases (donde los casos

positivos representan menos del 15% del total muestral). Inicialmente, la aplicación de técnicas de sobremuestreo sintético (SMOTE) combinado con un umbral clásico de decisión del 50 % (0,50) generó un volumen inaceptable de 45 Falsos Negativos, lo que ponía en riesgo la vida de estudiantes vulnerables al catalogarlos como “sanos”.

Para corregir esto de raíz, se reestructuró el pipeline implementando el algoritmo **XGBoost (Extreme Gradient Boosting)** optimizado. En lugar de crear datos artificiales con SMOTE –que introducen ruido en las encuestas–, se explotó el parámetro interno `scale_pos_weight` establecido dinámicamente según la proporción matemática inversa de las clases en el conjunto de entrenamiento.

Posteriormente, se ejecutó una búsqueda hiperparamétrica exhaustiva mediante `RandomizedSearchCV` controlando la tasa de aprendizaje (`learning_rate`) y la profundidad de los árboles (`max_depth`), mitigando el sobreajuste. Finalmente, para alcanzar el “punto dulce” óptimo, se descartó el umbral arbitrario y se barrió la curva Precisión-Recall, maximizando matemáticamente el F1-Score general del sistema. El umbral óptimo se localizó en 0,46. Los impactos en la matriz de confusión se reflejan en la Tabla 2.

Cuadro 2
Matriz de Confusión: Evolución del Pipeline Predictivo

Métrica / Estado	XGBoost Base	Ajuste (0.35)	Óptimo (0.46)
Verdaderos Negativos	621	446	584
Falsos Positivos	138	313	175
Falsos Negativos	45	22	29
Verdaderos Positivos	63	86	79
F1-Score Clase 1	0.4077	0.3392	0.4365

La Tabla 2 demuestra la evolución del comportamiento del modelo. El ajuste extremo a 0,35 reducía los Falsos Negativos a 22, pero disparaba los Falsos Positivos a 313, generando un colapso operativo por saturación de falsas alarmas. La optimización matemática en el umbral 0,46 redujo los Falsos Negativos de 45 a solo 29 de forma controlada, conteniendo los Falsos Positivos en 175 y alcanzando el F1-Score más alto y balanceado del experimento (0,4365).

Adicionalmente, se evaluó la capacidad de discriminación del modelo mediante la Curva ROC (Receiver Operating Characteristic), obteniéndose un Área Bajo la Curva (AUC) de **0.87**. Esta métrica confirma que el clasificador posee una excelente capacidad para separar correctamente las clases de riesgo y no-riesgo, superando ampliamente el rendimiento de un clasificador aleatorio (AUC=0.5). La curva ROC correspondiente se presenta en la Figura 1.

4. INTERPRETACIÓN Y FACTORES DETERMINANTES

La extracción de las propiedades de importancia intrínseca del modelo (Feature Importance) permitió identificar los vectores conductuales y contextuales que detonan el riesgo en salud mental en los adolescentes salvadoreños. Las Figuras 4 y 5 muestran las variables más relevantes para cada tarea.




Figura 1. Curva ROC del mejor modelo de clasificación optimizado para la detección de riesgo en salud mental.




Figura 2. Matriz de confusión del mejor modelo de clasificación sobre el conjunto de prueba, aplicando el umbral óptimo calibrado mediante la curva Precisión-Recall.

Los tres factores con mayor peso predictivo arrojados por el algoritmo corresponden a:

- 1. **Acoso Escolar (Bullying):** La frecuencia de agresiones físicas o verbales dentro de las instalaciones escolares representó el predictor con mayor ganancia de información en los árboles de decisión.
- 2. **Ausencia de Factores de Protección Familiar:** Variables asociadas al monitoreo y acompañamiento de los padres (conocimiento de qué hacen los jóvenes




Figura 3. Análisis de residuos del modelo de regresión (IMC): dispersión de residuos vs. predicción y distribución de errores.




Figura 4. Feature Importance del mejor modelo de clasificación de riesgo en salud mental. Las etiquetas provienen del codebook semántico del proyecto.




Figura 5. Feature Importance del mejor modelo de regresión de IMC.

en su tiempo libre o comprensión de sus problemas) exhibieron una correlación inversa directa con la presencia de riesgo.

- 3. **Consumo Temprano de Sustancias:** El acceso y consumo precoz de alcohol y tabaco actúa como un fuerte catalizador de desequilibrio emocional y sintomatología de riesgo.

5. RECOMENDACIONES DE POLÍTICA PÚBLICA

Traduciendo los hallazgos técnicos en decisiones estratégicas para el despacho ministerial, se plantean los siguientes ejes de intervención focalizada:

- **Despliegue de Unidades Móviles de Salud Mental Escolar:** Utilizando el modelo predictivo optimizado (umbral 0.46), el MINSAL puede mapear y clasificar los centros escolares del país. Aquellas escuelas cuyas encuestas agregadas arrojen altas probabilidades de riesgo colectivo deben recibir de forma prioritaria la asignación de psicólogos en planta, optimizando el presupuesto público del plan nacional de salud.
- **Intervención Interinstitucional MINSAL-MINED contra el Bullying:** Dado que el acoso escolar es la variable predictora predominante, no es posible solucionar la salud mental desde un enfoque puramente hospitalario. Se vuelve mandatorio co-diseñar junto al Ministerio de Educación protocolos vinculantes de prevención de violencia escolar, actuando directamente sobre la raíz del vector de riesgo.

- **Red de Alerta Temprana Automatizada:** Implementar a nivel nacional la infraestructura digital necesaria para que la GSHS u otros instrumentos de tamizaje escolar se digitalicen y procesen en tiempo real por este pipeline predictivo. Esto facultará a las regiones de salud del MINSAL a recibir alertas tempranas semestrales y mitigar incidentes de autolesión antes de su ocurrencia.
- **Fortalecimiento de la Salud Mental y Apoyo Social:** La alta importancia de variables relacionadas con sentimientos de soledad, falta de amigos cercanos o bullying sugiere que el Ministerio debe priorizar el establecimiento de programas de contención psicológica y consejería escolar. Se recomienda la implementación de Clubes de Apoyo entre Pares; la capacitación de docentes para detectar signos tempranos de aislamiento social.
- **Prevención del Consumo de Sustancias:** La relevancia de las variables asociadas al consumo de alcohol o drogas indica una fuerte asociación con el riesgo de salud mental. Se sugiere intensificar las campañas de prevención en los centros educativos, enfocadas en la educación sobre los riesgos del consumo de sustancias, y establecer rutas claras de derivación a servicios de salud para jóvenes que presenten esta conducta.
- **Promoción de Entornos Escolares Seguros:** Las variables asociadas a experiencias de violencia y acoso escolar deben abordarse mediante políticas orientadas a la creación de protocolos estrictos contra el acoso (*anti-bullying*) y a la promoción de una cultura de respeto y no violencia dentro de las aulas. Esto incluye la creación de canales anónimos para reportar incidentes de acoso.
- **Educación Nutricional y Hábitos Saludables:** Aunque el modelo de IMC tuvo un rendimiento bajo, la presencia de variables alimentarias en el top 10 de la clasificación sugiere un vínculo entre los hábitos de alimentación no saludables y el deterioro de la salud mental. Se recomienda fomentar programas de alimentación saludable y huertos escolares que no solo aborden la nutrición, sino que también funcionen como espacios de integración social.

En conclusión, el sistema predictivo propuesto ofrece una herramienta de priorización para el MINSAL, permitiendo focalizar recursos (psicólogos, campañas, talleres) en las escuelas con mayor índice de riesgo, identificado a través de las variables de comportamiento que hemos destacado.

6. CONCLUSIONES

Este proyecto demuestra el inmenso valor de la Ciencia de Datos orientada a la salud de la República de El Salvador. Mediante la correcta estructuración y preprocesamiento de la información de la GSHS, se superó el obstáculo de los valores nulos anómalos y se previno el sesgo por Data Leakage al eliminar variables antropométricas en la estimación del IMC. Asimismo, la calibración matemática del umbral de decisión en el modelo XGBoost proveyó al Ministerio de Salud de una herramienta validada científicamente que balancea la sensibilidad clínica con la viabilidad financiera

y operacional del estado, sentando las bases para una medicina preventiva moderna basada en algoritmos predictivos robustos.

REFERENCIAS

- [1] Organización Mundial de la Salud, “Encuesta Global de Salud Escolar (GSHS): Resultados Oficiales de la República de El Salvador”, OPS/OMS, 2013.
- [2] T. Chen and C. Guestrin, “XGBoost: A Scalable Tree Boosting System”, en *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, 2016, pp. 785-794.
- [3] J. Friedman, “Greedy function approximation: A gradient boosting machine”, *Annals of Statistics*, vol. 29, no. 5, pp. 1189-1232, 2001.
- [4] F. Pedregosa *et al.*, “Scikit-learn: Machine learning in Python”, *Journal of Machine Learning Research*, vol. 12, pp. 2825-2830, 2011.